

파노픽 분할(Panoptic Segmentation) 기반 철 스크랩 분류

나주원¹ · 장준희² · 김민엽⁴ · 이지홍⁴ · 심지훈⁴ · 윤준석¹ · 김세종^{3, #}

Steel Scrap Segmentation via Panoptic Segmentation Approach

J. W. Na, J. H. Jang, M. Y. Kim, J. H. Lee, J. H. Shim, J. S. Yoon, and S. J. Kim

(Received November 16, 2025 / Revised November 26, 2025 / Accepted November 27, 2025)

Abstract

Steel scrap represents a critical recyclable feedstock in the steel industry, serving as a key raw material in electric arc furnace steelmaking processes while significantly reducing CO₂ emissions and waste generation. Reliable classification and grading of steel scrap are essential for quality assurance in the steel recycling chain. However, conventional manual inspection depends heavily on operator expertise and becomes inefficient and inconsistent when large volumes must be processed. To overcome these challenges, this study, for the first time, proposes a panoptic segmentation-based framework for steel scrap classification, which simultaneously identifies both steel scrap types (semantic information) and individual instances (instance information) for all scrap objects in an image. The proposed model adopts the MaskDINO architecture with a Transformer encoder-decoder and a ResNet-50 backbone, and is trained on high-resolution 4K steel scrap images of truck cargos collected under diverse stockyard conditions, including daytime, nighttime, and rainy weather. Experimental results demonstrate that our model achieves 80.2% accuracy in counting steel scrap objects and 86.9% accuracy in area ratio estimation across diverse steel scrap classes. Notably, the model exhibits robust performance even in challenging scenarios involving overlapping or irregularly shaped steel scrap objects. These results indicate that our approach can serve as a practical foundation for large-scale, consistent, and real-time steel scrap grading in industrial environments.

Keywords : Steel scrap, Computer vision, Panoptic segmentation

1. 서 론

철 스크랩은 철강재 생산·가공 과정 또는 사용 후 폐기된 철강제품을 회수하여 철강재 생산에 재 활용하는 대표적인 2차 철원으로서, 전기로 제강 공정에서 주요 원료로 활용되며, 환경적으로 CO₂ 배출량과 폐기물 발생을 크게 감축하는 효과를 가진 친환경 원료로 주목받고 있다[1-4]. 특히, 철 스크랩은 국내에서 상당 부분을 자체 조달할 수 있는 철

강 원료로서, 안정적인 철원 확보와 탄소중립 실현을 위해 그 중요성이 더욱 커지고 있다.

철 스크랩의 유통 구조는 발생원에서 수집된 철 스크랩이 가공 및 등급 분류 과정을 거쳐 최종적으로 제강사에 공급되는 형태로 이루어진다. 이때, 철 스크랩의 등급 판정은 적정 가격 산정과 품질 관리에 직결되는 핵심 과제이다. 그러나 기존의 철 스크랩 분류 방식은 현장 작업자의 육안 판정에 전적으로 의존하고 있어 여러 문제점이 존재한다. (1) 작업자의 경험과 숙련도에 따라 분류 결과가 상이하여 일관성이 결여되며, (2) 대량의 철 스크랩을 처리할 때 시간과 비용이 과다하게 소요되어 그 효율성이 낮다. 이러한 한계를 극복하기 위해, 컴퓨터 비전과 인공지능 기술을 활용한 철 스크랩 분류 시스템의

1. 한국재료연구원, 선임연구원

2. 한국재료연구원, 연구원

3. 한국재료연구원, 책임연구원

4. ITIV AI, 연구원

#Corresponding Author: Korea Institute of Materials Science,
E-mail: ksj1009@kims.re.kr, ORCID: 0000-0001-7051-8057

필요성이 대두되고 있다.

최근 딥러닝(deep learning)[5] 기반 컴퓨터 비전 기술의 발전으로 이미지 기반 객체 인식 및 분류 기술이 고도화되면서, 철 스크랩과 같은 복잡한 형태의 물체를 자동으로 분류할 수 있는 가능성이 열렸다. 선행 연구들은 이미지 분류(image classification)[6], 객체 탐지(object detection)[7-9], 의미론적 분할(semantic segmentation)[10, 11] 접근법을 활용하여 철 스크랩을 분류하는 연구를 수행해왔다. 인공지능을 활용한 철 스크랩 분류의 가능성을 보여주었으나, 철 스크랩의 종류(semantic)와 개별 객체(instance)를 동시에 식별하지 못한다는 근본적인 한계점을 가지고 있다. 이는 철 스크랩 등급 판정 및 등급별 비율 산출을 저해하는 요인으로 작용한다.

본 연구에서는 이러한 문제를 해결하기 위해 파놉틱 분할(panoptic segmentation) 기반 철 스크랩 분류 기술을 제안한다. 구체적으로, 트랜스포머(transformer) 기반 MaskDINO 아키텍처를 적용하여 철 스크랩 종류와 개별 객체를 동시에 식별하는 모델을 개발하였다. 실제 야적장 환경에서 수집한 철 스크랩 이미지 데이터를 통해 모델의 실용성을 검증하였으며, 비교 모델들과의 정량·정성 평가를 통해 제안 모델의 우수성을 입증하였다. 제안하는 기술은 일관된 기준으로 대량·실시간 철 스크랩 분류를 가능하게 함으로써 철 자원 순환 시스템의 효율적 운영에 기여할 수 있다.

2. 배경 지식

2.1 철 스크랩 분류 체계

한국산업표준 KS D 2101에 따르면 철 스크랩은 대표적으로 다섯 가지 범주로 분류된다. 첫째, 생철 스크랩은 고로 공정에서 발생하는 내부 순환 스크랩과 1차 가공 과정에서 발생하는 불순물이 거의 없는 스크랩으로 구성된다. 둘째, 중량 스크랩은 형강, 봉강, 기계 구조물, 파이프류 등 부피 대비 비중이 비교적 큰 스크랩을 포함한다. 셋째, 경량 스크랩은 경량 구조물, 생활 고철 등 부피 대비 비중이 작은 스크랩으로, 형상과 크기가 불규칙한 경우가 많다. 넷째, 선반 스크랩은 절삭 가공 시 발생하는 칩 형태의 스크랩으로 구성되며, 대체로 길고 가는 형상을 가진다. 다섯째, 가공 스크랩은 전기로에 직접 투입하기 어려운 형태나 크기의 스크랩을 절단

·가공하여 공급하는 스크랩으로, 기타 절단 칩 및 재가공된 스크랩을 포함한다. 이러한 분류 체계는 철 스크랩의 물리적 특성과 재활용 가능성을 기준으로 설계되었으며, 전기로 제강 과정에서의 활용도와 품질 등급이 상이하다.

2.2 이미지 분할 기술

이미지 분할 기술은 컴퓨터 비전의 한 분야로서, 이미지를 의미 있는 영역으로 분할하는 기술이다. 대표적인 세 가지 접근법은 의미론적 분할(semantic segmentation)[12, 13], 객체 분할(instance segmentation)[14], 파놉틱 분할(panoptic segmentation)[15, 16]으로 구분된다. 첫째, 의미론적 분할은 이미지의 각 픽셀을 특정 클래스로 분류하는 기법으로, 이미지 내 객체의 종류를 식별할 수 있도록 하는 한편, 개별 객체의 구분은 불가능하다는 한계가 있다. 예를 들어, 여러 개의 파이프가 있을 때 모두 '파이프' 클래스로 분류되지만 각각을 독립적인 객체로 식별하지 못한다. 둘째, 객체 분할은 이미지 내 각 객체를 개별적으로 식별하는 기법이다. 하지만, 각 객체의 클래스에 대한 정보를 제공하지 못하는 한계가 존재한다. 마지막으로, 파놉틱 분할은 이 두 가지 접근법을 결합한 기법으로, 이미지의 모든 픽셀에 대해 클래스와 인스턴스 정보를 동시에 제공한다. 즉, 철 스크랩 종류와 개별 객체를 한 번에 식별할 수 있어, 철 스크랩 종류별 비율을 산출하는 데 적합하다.

3. 사전 연구

인공지능을 활용한 철 스크랩 분류에 대한 연구는 최근 활발히 진행되어 왔으며, 크게 이미지 분류(image classification), 객체 탐지(object detection), 의미론적 분할(semantic segmentation) 세 가지 접근법으로 분류할 수 있다.

이미지 분할 접근법은 전체 이미지를 단일 클래스로 분류하는 방식으로, 철 스크랩 분류의 기초적인 자동화를 시도하였다[6]. 이러한 접근법은 비교적 높은 철 스크랩 분류 정확도를 보였으나, 이미지 전체를 단일 클래스로만 분류하기 때문에 혼합된 철 스크랩 환경에서 각 클래스의 개별 객체 수나 면적 비율을 산출할 수 없다는 근본적인 한계가 존재한다.

객체 탐지 접근법은 이미지 내 개별 객체를 바운딩 박스로 검출하고 분류하는 방식으로, Classification

의 한계를 일부 극복하였다. Xu[7]은 9가지 종류의 철 스크랩을 분류하는 시스템을 제안하였다. 또한 일부 연구들에서는 YOLO 알고리즘을 활용하여 철 스크랩의 개별 객체를 실시간으로 탐지하고 통계를 산출하는 시스템을 개발하였다[8, 9]. 그러나 객체 탐지 방식은 바운딩 박스 기반 접근법의 한계로 인해 정확한 면적 측정이 불가능하다. 특히 철 스크랩이 서로 겹쳐있거나 불규칙한 형태를 가진 경우, 바운딩 박스가 실제 객체 면적보다 훨씬 큰 영역을 포함하게 되어 면적 기반 비율 산출에 상당한 오차가 발생한다.

의미론적 분할 접근법은 이미지의 모든 픽셀에 대해 클래스를 분류하는 방법으로, 철 스크랩의 면적 기반 비율 산출에 유용하다. Daigo[10]은 MSPFNet (Multi-Scale Perceptual Focusing Network)을 제안하여 복잡한 형태의 철 스크랩 이미지의 분할을 가능하게 하였다. 또한 Zhong[11]은 웨이블릿 변환과 다중 스케일 포커싱 구조를 결합한 WaveSegNet을 제안하여 철 스크랩 세그멘테이션 정확도를 향상시켰다. 그러나 이러한 의미론적 분할 방식은 픽셀 수준의 정밀한 분류를 통하여 철 스크랩 종류별 면적 비율을 산출 가능하게 하지만, 개별 객체들을 구분하지 못한다는 한계점을 가지고 있다. 예를 들어, 이미지 내에 동일한 종류의 철 스크랩이 여러 개 존재하더라도 이를 하나의 연결된 영역으로 인식하는 문제가 발생한다.

세 가지 접근법은 다음과 같은 한계를 가지고 있다. (1) 이미지 분류 방식은 단일 이미지 수준의 분류만 가능하여 클래스별 비율 산출이 근본적으로 불가능하다. (2) 객체 탐지 접근법은 철 스크랩 종류별 개수 산정은 가능하나 정확한 면적 측정이 불가능하다. (3) 의미론적 분할은 철 스크랩 종류별 면적 측정은 가능하나 개별 객체 정보를 제공하지 않는다. 이러한 한계들은 모두 철 스크랩 등급 판정에 필요한 정확한 비율 산출을 저해하는 요인이 된다.

4. 방법론

4.1 파놉틱 분할 모델

파놉틱 분할은 이미지의 모든 픽셀에 대해 클래스와 인스턴스 정보를 동시에 제공한다. 여기서 클래스는 철 스크랩의 종류(파이프, 판재 등)를 의미하며, 인스턴스는 동일한 클래스에 속하더라도 각각을

독립적인 개체로 구분하는 것을 의미한다. 이는 철 스크랩의 종류와 개별 객체를 동시에 식별해야 하는 본 연구 목표에 적합한 방법론이다. 결과적으로, 파놉틱 분할 방식을 통해 철 스크랩 객체 개수를 정확히 파악하고, 각 객체의 픽셀 수준 분할 영역(segmentation mask)으로부터 면적을 계산하여 전체 대비 비율을 산출할 수 있다.

본 연구에서 개발한 철 스크랩 분류 AI 모델은 MaskDINO[17] 구조를 기반으로 한다. MaskDINO는 Transformer encoder-decoder[18] 구조를 채택하고 있으며, ResNet-50[19]을 백본 네트워크로 사용하여 입력 이미지로부터 다층 특징 표현(multi-level feature maps)을 추출한다. 추출된 특징맵(feature map)은 Transformer encoder를 거쳐 이미지 전역에 걸친 맥락 정보(global context)가 강화되며, decoder는 학습 가능한 객체 쿼리(object queries)를 사용하여 각 철 스크랩 객체를 탐지하고 픽셀 단위 분할 영역(segmentation mask)을 생성한다.

모델의 출력은 크게 세 가지로 구성된다. 첫째, 클래스 예측으로 각 쿼리가 어떤 철 스크랩 종류에 해당하는지 분류한다. 둘째, 바운딩 박스 예측으로 객체의 위치를 특정한다. 셋째, 마스크 예측으로 픽셀 수준의 정밀한 객체 경계를 예측한다. 이 세 가지 예측은 클래스 분류 손실(classification loss), 바운딩 박스 회귀 손실(box regression loss), 마스크 예측 손실(mask prediction loss)을 가중합한 통합 손실 함수를 통해 동시에 최적화되며, 이는 end-to-end 학습을 가능하게 한다.

모델 학습은 NVIDIA A6000 GPU를 사용하여 수행하였다. 학습 데이터는 8:2의 비율로 훈련 세트와 테스트 세트로 분할하였으며, 세 가지의 데이터 증강 기법(random flip, random crop, color jittering)을 적용하여 모델의 일반화 성능을 향상시켰다. 배치 크기는 4로 설정하였으며, AdamW 옵티마이저를 사용하여 학습률 0.0001로 총 50 에포크 동안 학습을 진행하였다. 전체 학습 소요 시간은 약 12시간이었으며, 학습된 모델의 추론 속도는 4K 해상도 이미지 1장당 약 0.7초로, 실시간 처리가 가능한 수준임을 확인하였다.

4.2 데이터 수집

데이터는 철 스크랩 야적장에 설치한 고해상도 카메라를 통해 수집하였다. 본 연구에서 사용하는




Fig. 1 Example of annotated steel scrap image

이미지는 트럭 카고(cargo) 상부를 수직에 가깝게 촬영한 이미지이며, 다양한 상황을 반영하기 위해 주간, 야간, 우천 등 여러 기상 조건에서 데이터를 수집하였다. 수집된 이미지는 3840×2160 해상도의 4K 이미지로 저장되었으며, 여러 종류의 철 스크랩이 혼재된 실제 적재 상태를 포함하는 데이터셋을 구축하였다.

4.3 데이터 어노테이션

파놉틱 분할 모델 학습을 위해서는 각 객체의 클래스 정보와 정확한 픽셀 단위 분할 영역 정보가 필요하다. 본 연구에서는 오픈소스 레이블링 도구를 활용하여 데이터 어노테이션 작업을 수행하였다. 총 10종의 철 스크랩 종류를 클래스로 정의하였으며, 약 1,000개의 개별 객체에 대해 픽셀 수준의 마스크를 생성하였다. 주요 클래스로는 Scrap automotive parts, Scaffold base plate, Pipe, Square steel pipe, Panels, Guillotine, House pipe가 포함되었다. 각 클래스는 현장 전문가의 자문을 통해 실제 철강 산업에서 사용되는 용어와 분류 기준을 반영하였으며, 철 스크랩 명칭은 사전에 정의된 룩업(look-up) 테이블을 통해 KSD 2101 등급으로 변환될 수 있다.

4.4 평가 지표

철 스크랩 분류의 최종 목표는 철 스크랩 종류별 비율을 산출하는 것이므로, 본 연구에서는 비율 산출 정확도를 중심으로 모델 성능을 평가하였다. 평가 지표는 크게 두 가지로 구성된다.

첫째, 클래스별 객체 개수 정확도(count accuracy)는

각 클래스에서 예측된 객체 개수가 실제값(ground truth) 개수와 얼마나 일치하는지 측정한다. 상대 정확도(relative accuracy)를 사용하여 다음과 같이 계산한다:

$$Count\ Acc. = \frac{1}{N} \sum_{i=1}^N \left[1 - \frac{|C_{pred}^{(i)} - C_{gt}^{(i)}|}{C_{gt}^{(i)}} \right] \quad (1)$$

여기서 N 은 철 스크랩 종류 개수, C_{pred} 와 C_{gt} 는 각각 철 스크랩 종류별 예측된 객체 개수와 실제 객체 개수를 나타낸다.

둘째, 클래스별 면적 비율 정확도(area ratio accuracy)는 각 클래스가 전체 면적에서 차지하는 비율이 실제값 비율과 얼마나 일치하는지 측정한다:

$$Area\ Ratio\ Acc. = \frac{1}{N} \sum_{i=1}^N \left[1 - \frac{|R_{pred}^{(i)} - R_{gt}^{(i)}|}{R_{gt}^{(i)}} \right] \quad (2)$$

여기서 R_{pred} 와 R_{gt} 는 각각 철 스크랩 종류별 예측된 면적 비율과 실제 면적 비율을 백분율(%)로 나타낸 값이다.

또한, 본 연구에서는 PQ(panoptic quality) 지표를 사용하여 철 스크랩 파놉틱 분할 성능을 종합적으로 평가한다:

$$PQ = \frac{\sum_{(p,g) \in TP} IoU(p,g)}{|TP| + \frac{1}{2}|FP| + \frac{1}{2}|FN|} = SQ \times RQ, \quad (3)$$

$$where\ IoU(p,g) = \frac{|p \cap g|}{|p \cup g|}$$

여기서 IoU (intersection over union)는 예측 객체 마스크 p 와 실제 객체 마스크 g 간의 겹치는 정도를 측정하는 지표이며, TP (true positive)는 IoU 가 0.5 이상인 예측-실제 마스크 쌍의 수를 의미한다. FP (false positive)와 FN (false negative)은 각각 실제 객체 마스크에 대응되지 않은 예측 객체 마스크 수, 예측된 객체 마스크에 대응되지 않은 실제 객체 마스크 수를 의미한다. SQ (segmentation quality)는 픽셀 수준에서의 분할 정확도를 의미하며, RQ (recognition




Fig. 2 Qualitative results of steel scrap panoptic segmentation

quality)는 객체 수준에서의 검출 정확도를 측정한다. 따라서, PQ 는 객체 인식 정확도와 분할 품질을 동시에 평가할 수 있다.

5. 결 과

5.1 정성적 결과 분석

Fig. 2는 제안하는 모델의 철 스크랩 분류 결과를 시각적으로 나타낸다. 상단 이미지는 10종의 철 스크랩이 혼재된 트럭 카고를 보여주며, 모델은 Panels, Square steel pipe, Pipe, Guillotine 등 여러 클래스를 동시에 인식하고 각 객체를 개별 인스턴스로 분할한다. 하단 이미지는 주로 Guillotine 클래스가 대량으로 적재된 사례이며, 우천 상황에서 촬영된 이미지임에도 불구하고 불규칙한 형상과 밀집된 적재 상태에서 모델이 각 객체의 경계를 명확히 구분하고 철 스크랩 클래스를 정확히 할당한 것을 확인할 수 있다.

그림에서 제시된 Prediction과 Ground Truth를 비교하면, 제안 모델의 예측이 실제 정답 레이블과 유사함을 확인할 수 있다. 특히 서로 겹치거나 부분적으로 가려진 스크랩에서도 인접 객체 간 경계를 비교적 정확히 구분하는 등, 파네틱 접근법이 실제 산업 현장 환경에서 유효하게 작동함을 정성적으로 확인할 수 있다.

5.2 정량적 결과 분석

철 스크랩 등급 판정 및 비율 산출의 정확성을 검증하기 위해, 제안 모델의 성능을 정량적으로 분석한다. 평가는 크게 두 가지 측면에서 수행된다. 첫째, 철 스크랩 종류별 객체 개수 예측 정확도를 분석하여 모델이 개별 인스턴스를 얼마나 정확히 식별하는지 검증한다. 둘째, 철 스크랩 종류별 면적 비율 예측 정확도를 평가하여 픽셀 수준의 분할 성능이 실제 철 스크랩 종류별 비율 산출에 얼마나 기여하는지 확인한다. 정량적 결과는 제안 모델이 실제 산업 현장에서 활용될 수 있는 수준의 성능을 보임을 입증한다.

5.2.1 철 스크랩 객체 개수 정확도

Fig. 3은 개별 철 스크랩 종류에 대한 객체 개수 예측 결과를 보여준다. 파란색 바(bar)는 실제 개수를, 빨간색 막대는 제안 모델의 예측 개수를 나타낸다. 전체 테스트 데이터셋에서 제안 모델은 평균 80.2%의 객체 개수 정확도를 달성하였다. Panels 클래스의 경우 실제 개수 117개에 대해 모델이 126개를 예측하여 92.3%의 높은 정확도를 보였으며, Guillotine 클래스는 실제 개수 44개 중 40개를 예측하여 90.9% 정확도를 달성하는 등 출현 빈도가 잦은 주요 클래스에서 예측 개수와 정답 개수가 높은 정확도로 일치하는 결과를 확인하였다. Automotive




Fig. 3 Count accuracy for each steel scrap class




Fig. 4 Area ratio accuracy for each steel scrap class

parts, Scaffold base plate 등 상대적으로 작은 객체나 복잡한 형상을 가진 클래스에서는 약간의 오차가 발생하였으나, 대부분 3~4개 이내 범위에 머무른다.

전체적으로 모델의 예측과 실제 개수의 분포는 유사하며, 이는 제안 모델이 철 스크랩 개수를 높은 정확도로 산정할 수 있음을 정량적으로 입증한다. 이러한 결과는 파놉틱 분할 방식이 객체 정보를 제공한다는 점을 잘 반영하며, 철 스크랩 통계와 공정 관리에 활용될 수 있다.

5.2.2 철 스크랩 면적 비율 정확도

철 스크랩 종류별 면적 예측은 철 스크랩 등급 비율 산정의 핵심 요소이다. 픽셀 단위로 예측된 각 클래스의 분할 영역 면적을 합산하여 전체 면적 대비 비율을 계산한 후 사전에 정의된 룩업 테이블을 통해 개별 철 스크랩 클래스를 KS D 2101 등급으로 변환함으로써, 최종적으로 등급 판정 및 등급별 비율 산출을 가능하게 한다. Fig. 4는 전체 테스트 데이터셋에 대한 주요 철 스크랩 클래스별 면적(픽셀 단위) 예측 결과를 보여준다.




Fig. 5 Panoptic quality for each steel scrap class

전체적으로 모든 클래스에서 예측 면적(빨간색 바)과 실제 면적(파란색 바)이 거의 겹쳐져 있는 것을 볼 수 있으며, 86.9%의 면적 비율 정확도를 보였다. 클래스별로 살펴보면, Guillotine 클래스가 전체 면적에서 가장 큰 비중을 차지하였으며, 모델의 예측값이 실측값과 거의 일치하는 것을 확인할 수 있다. 이는 대형 철 스크랩 객체에 대해 모델이 정확한 픽셀 단위 분할을 생성하고 면적을 측정할 수 있음을 보여준다. Panels 클래스는 두 번째로 큰 면적 비중을 차지하였으며, 실측값 대비 예측값의 오차가 0.5%로 매우 작은 것을 확인할 수 있다. House pipe와 Automotive part 클래스의 경우 상대적으로 작은 면적 비중을 차지하지만, 제안 모델은 이들 클래스에 대해서도 일관된 정확도로 면적을 예측하였다.

전체적으로 모든 클래스에서 예측과 정답 면적의 분포는 유사하며, 이는 제안 모델이 철 스크랩 종류별 면적 비율을 정확하게 산출할 수 있음을 정량적으로 보여준다. 기존의 바운딩 박스 기반 철 스크랩 객체 탐지 연구들은 철 스크랩의 불규칙한 형상 때문에 실제 객체보다 큰 영역을 포함하여 면적 추정에 큰 오차를 야기하는 반면, 제안하는 파놉틱 분할 기반 접근법은 객체 경계를 픽셀 수준에서 정밀하게 추정함으로써 면적 측정의 정확도를 크게 향상시킨다. 이러한 특성은 최종적으로 등급별 비율 산정의 신뢰도를 높이는 데 결정적인 역할을 한다.

5.2.3 철 스크랩 파놉틱 분할 성능

Fig. 5는 철 스크랩 클래스별 PQ 성능을 나타낸다. 철 스크랩 객체를 나타내는 Things 클래스들은 분홍색 막대로, 배경 영역을 나타내는 Stuff 클래스인 Ground는 노란색 막대로 표시된다. 클래스별 PQ 값

을 살펴보면, House pipe와 Magnet 클래스가 각각 0.82, 0.81의 가장 높은 PQ를 달성하였으며, Automotive parts, Incorner, Pipe 클래스도 각각 0.73, 0.71, 0.70으로 우수한 파놉틱 분할 성능을 보였다. 이는 해당 클래스들에 대해 모델이 객체 인식과 픽셀 수준의 경계 분할을 모두 정확하게 수행할 수 있음을 의미한다. Guillotine와 Panels 클래스는 각각 0.57, 0.27의 PQ를 기록하였으며, 이는 비교적 대형 객체임에도 불구하고 불규칙한 형상으로 인해 객체 간 경계 구분이 어려웠기 때문으로 분석된다. Square steel pipe, Handler, Scaffold base plate 클래스는 각각 0.41, 0.38, 0.34의 중간 수준 PQ를 나타냈다. 전체적으로 제안 모델은 대부분의 철 스크랩 클래스에서 안정적인 파놉틱 분할 성능을 보이며, 평균 PQ 0.55를 달성하여 철 스크랩의 종류 분류와 개별 객체 분할을 동시에 수행할 수 있음을 보였다.

6. 결 론

본 연구에서는 파놉틱 분할 접근법 기반의 철 스크랩 분류 기술을 제안하였다. 제안 모델은 철 스크랩 종류와 개별 객체를 동시에 인식함으로써, 기존 이미지 분류, 객체 탐지, 의미론적 분할 기반의 사전연구들이 가지고 있던 한계를 모두 해결한다.

실제 야적장 환경에서 수집한 철 스크랩 이미지에 대해 학습 및 검증한 결과, 제안 모델은 객체 개수 예측 정확도 80.2%, 면적 비율 정확도 86.9%를 보였다. 특히, 정성적 분석에서는 철 스크랩이 서로 겹치거나 복잡하게 쌓여 있는 경우에도 개별 객체 경계를 명확히 구분하고 철 스크랩 클래스를 할당하는 것을 확인하였으며, 정량적 분석에서는 Panels, Guillotine, Square steel pipe 등 주요 클래스에서 예측 개수와 면적이 정답과 거의 일치하는 분포를 보였다. 이러한 결과는 철 스크랩의 비율을 정확히 산출함으로써 제안 모델이 실질적인 산업 요구를 충족할 수 있음을 입증한다. 더 나아가, 제안 시스템은 4K 해상도 이미지 기준 약 0.7초의 추론 시간을 보여, 대량의 철 스크랩 데이터를 실시간으로 처리할 수 있는 효율성을 확보하였다.

이러한 시스템은 철강 산업의 효율성 향상과 공정한 가격 산정에 기여할 것으로 기대되며, 향후 실제 야적장 환경에서의 실시간 배포 및 성능 검증을 통해 상용화 가능성을 확인할 계획이다.

후 기

본 연구는 산업통상자원부의 “소재부품기술개발사업(과제번호 RS-2024-00448829)”의 지원을 받아 수행되었다.

REFERENCES

- [1] R. J. Compañero, A. Feldmann, A. Tilliander, 2021, Circular Steel: How Information and Actor Incentives Impact the Recyclability of Scrap, J. Sustain. Metall., Vol. 7, No. 4, pp. 1654-1670.
<https://doi.org/10.1007/s40831-021-00436-1>
- [2] C. Broadbent, 2016, Steel's Recyclability: Demonstrating the Benefits of Recycling Steel to Achieve a Circular Economy, Int. J. Life Cycle Assess., Vol. 21, No. 11, pp. 1658-1665.
<https://doi.org/10.1007/s11367-016-1081-1>
- [3] M. Sahoo, S. Sarkar, A. C. R. Das, G. G. Roy, P. K. Sen, 2019, Role of Scrap Recycling for CO2 Emission Reduction in Steel Plant: A Model Based Approach, steel res. int., Vol. 90, No 8, 1900034.
<https://doi.org/10.1002/srin.201900034>
- [4] M. Yellishetty, G. M. Mudd, P. G. Ranjith, A. Tharumarajah, 2011, Environmental Life-cycle Comparisons of Steel Production and Recycling: Sustainability Issues, Problems and Prospects, Environ. Sci. Policy, Vol. 14, No. 6, pp. 650-663.
<https://doi.org/10.1016/j.envsci.2011.04.008>
- [5] Y. LeCun, Y. Bengio, G. Hinton, 2015, Deep Learning, Nature, Vol. 521, No. 7553, pp. 436-444.
<https://doi.org/10.1038/nature14539>
- [6] P. H. dos Santos, V. de Carvalho Santos, E. J. da Silva Luz, 2025, Towards Robust Ferrous Scrap Material Classification with Deep Learning and Conformal Prediction, Eng. Appl. Artif. Intell., Vol. 140, 109724.
<https://doi.org/10.1016/j.engappai.2024.109724>
- [7] W. Xu, P. Xiao, L. Zhu, Y. Zhang, J. Chang, R. Zhu, Y. Xu, 2023, Classification and Rating of Steel Scrap Using Deep Learning, Eng. Appl. Artif. Intell., Vol. 123, 106241.
<https://doi.org/10.1016/j.engappai.2023.106241>
- [8] W. Xu, P. Xiao, L. Zhu, G. Wei, R. Zhu, 2024, An

- Efficient Treatment Method of Scrap Intelligent Rating Based on Machine Vision, *Appl. Intell.*, Vol. 54, No. 21, pp. 10912-10928.
<https://doi.org/10.1007/s10489-024-05581-0>
- [9] L. Wang, Y. Xu, R. Li, S. Yang, P. Liu, H. Li, 2025, A Steel Scrap Recognition Model Based on Machine Vision, *J. Meas. Eng.*, Vol. 13, No. 2, pp. 236-246.
<https://doi.org/10.21595/jme.2024.24321>
- [10] Y. Xu, C. Liu, J. Zhong, W. Mei, Y. Zhang, 2025, MSPFNet: Multi-scale Perceptual Focusing Network for Scrap Steel Segmentation and Classification, *Eng. Appl. Artif. Intell.*, Vol. 144, 110084.
<https://doi.org/10.1016/j.engappai.2025.110084>
- [11] J. Zhong, Y. Xu, C. Liu, 2024, WaveSegNet: An Efficient Method for Scrap Steel Segmentation Utilizing Wavelet Transform and Multiscale Focusing, *Mathematics*, Vol. 12, No. 9, 1370.
<https://doi.org/10.3390/math12091370>
- [12] J. Long, E. Shelhamer, T. Darrell, 2015, Fully Convolutional Networks for Semantic Segmentation, *Proc. IEEE Conf. Comput. Vis. Pattern Recognit.*, pp. 3431-3440.
<https://doi.org/10.1109/CVPR.2015.7298965>
- [13] O. Ronneberger, P. Fischer, T. Brox, 2015, U-Net: Convolutional Networks for Biomedical Image Segmentation, *Proc. Int. Conf. Med. Image Comput. Comput. Assist. Interv.*, pp. 234-241.
https://doi.org/10.1007/978-3-319-24574-4_28
- [14] K. He, G. Gkioxari, P. Dollár, R. Girshick, 2017, Mask R-CNN, *Proc. IEEE Int. Conf. Comput. Vis.*, pp. 2961-2969.
<https://doi.org/10.1109/ICCV.2017.322>
- [15] A. Kirillov, K. He, R. Girshick, C. Rother, P. Dollár, 2019, Panoptic Segmentation, *Proc. IEEE Conf. Comput. Vis. Pattern Recognit.*, pp. 9404-9413.
<https://doi.org/10.1109/CVPR.2019.00963>
- [16] A. Kirillov, R. Girshick, K. He, P. Dollár, 2019, Panoptic Feature Pyramid Networks, *Proc. IEEE Conf. Comput. Vis. Pattern Recognit.*, pp. 6399-6408.
<https://doi.org/10.1109/CVPR.2019.00656>
- [17] L. Feng, H. Wu, N. Xu, J. Song, L. Yu, 2023, Mask DINO: Towards a Unified Transformer-based Framework for Object Detection and Segmentation, *Proc. IEEE Conf. Comput. Vis. Pattern Recognit.*, pp. 3041-3050.
<https://doi.org/10.1109/CVPR52729.2023.00297>
- [18] A. Vaswani, N. Shazeer, N. Parmar, J. Uszkoreit, L. Jones, A. N. Gomez, L. Kaiser, I. Polosukhin, 2017, Attention is All You Need, *Proc. Adv. Neural Inf. Process. Syst.*, Vol. 30, pp. 5998-6008.
<https://doi.org/10.48550/arXiv.1706.03762>
- [19] K. He, X. Zhang, S. Ren, J. Sun, 2016, Deep Residual Learning for Image Recognition, *Proc. IEEE Conf. Comput. Vis. Pattern Recognit.*, pp. 770-778.
<https://doi.org/10.1109/CVPR.2016.90>