

철스크랩 데이터 라벨링 효율 및 모델 성능 최적화 연구

1. 연구 목적

본 연구의 목적은 스크랩 분류 모델의 성능을 유지 또는 향상시키면서 라벨링 작업의 효율성을 높이기 위한 Instance 정의 기준을 도출하는 것입니다.

현재 식별 가능한 객체를 모두 라벨링 하고 있는 상황입니다.

이 방식이 실제 모델 성능향상에 기여할 수 있는 수준인지에 대한 검토가 필요합니다.

특히 다음 사항에 대한 정량적 기준 도출을 요청드립니다.

- 모델 학습에 실질적으로 기여하는 최소 Instance 크기는 무엇인가?
- 어떤 크기까지 잘린 객체를 독립 Instance로 유지하는 것이 타당한가?

2. 데이터 현황

- 총 이미지 수: 약 2,000장
- 총 Instance 수: 약 400,000
- 총 클래스 수: 84개
- Instance Segmentation 기반 라벨링 수행
- YOLO 계열 모델 사용 중

(첨부파일 : 클래스별 instance 분포.csv [링크](#))

(첨부파일 : 전체 데이터셋.zip [링크](#))

3. 연구 요청 – Instance 최소 크기 및 형상 기준

3.1 연구 배경

현재 다음과 같은 상황이 발생하고 있습니다.


- 매우 작은 Instance까지 모두 라벨링 수행 중
- 겹쳐진 객체를 분리하여 개별 Instance로 정의
- 동일 제품 또는 동일 강종이라도
겹침, 절단, 구김, 파손 등에 따라 다양한 형상이 발생

이로 인해 다음과 같은 의문이 제기됩니다.

- 작은 Instance가 모델 성능에 실질적으로 기여하는가?
- 겹쳐져 잘린 조각을 어떤 크기까지 동일한 클래스로 분류해야하는가?
 - → Instance 형상이 얼마나 달라져야 다른 클래스로 구분해야 하는가?


3.2 예시 이미지

1. <전체 화각>




2. <겹쳐진 객체 분리 라벨링에 의해 작은 Instance가 발생한 사례>

- 민트색 폴리곤 Instance를 독립 객체로 유지하는 것이 타당한가?




3. <전체 화각>



4. <소형 Instance 라벨링 사례>

- 살구색, 노란색 Instance를 각각 독립 객체로 분류하는 것이 적절한가?



4. 연구 결과 산출물 요청

4.1 최소 Instance 크기 기준 도출

- 이미지 해상도 대비 분류 가능한 최소 Instance 크기는 무엇인가?
- 형상 차이에 따른 성능 변화 분석
- 원본, 겹침, 크기 차이 등을

별도 클래스로 분리하는 것이 실제로 성능 향상에 기여하는지 검증

“이미지 해상도 대비 N% 이하 크기의 Instance는 모델 성능에 유의미한 영향을 주지 않으므로 제거하여도 무방”

- 도출된 최소 Instance 크기 변화에 따른 분석 결과를 포함하여 요청드립니다.

5. 참고 사항

- 현재 라벨 데이터는 4K 해상도 기준으로 매우 정밀하게 Polygon이 구성되어 있습니다. 그에 따라, Polygon Point 수 과다로 인해 학습 Backward에서 OOM 발생할 수 있음을 확인한 상태입니다. 필요 시 Point 수 단순화 등의 전처리 후 비교 연구를 진행해야 할 수 있음을 알려드립니다.